

Pengembangan Perangkat Lunak Deteksi dan Forensik Jaringan DDoS Berbasis XGBoost dan Information Gain

Falito Eriano Nainggolan, Dimas Surya Pratama, Gita Olivia Silaban

Program Studi Rekayasa Keamanan Siber

Politeknik Siber dan Sandi Negara, Bogor, Indonesia

Email: falito.eriano@poltekssn.ac.id, dimas.surya@poltekssn.ac.id, gita.olivia@poltekssn.ac.id

Ringkasan—Serangan *Distributed Denial of Service* (DDoS) merupakan ancaman signifikan terhadap keamanan jaringan kampus. Penelitian ini mengembangkan DDoShield, sebuah aplikasi web untuk deteksi dan forensik DDoS menggunakan algoritma XGBoost dengan seleksi fitur *Information Gain* (IG). Eksperimen dilakukan pada dataset CIC-IDS2017 (225.745 sampel, 78 fitur) dengan variasi jumlah fitur $K = \{5, 10, 15, 20, 30, \text{all}\}$. Hasil pengujian menunjukkan bahwa XGBoost dengan $K = 30$ fitur optimal mencapai *F1-Score* sebesar 99,9977% dan AUC-ROC sebesar 1,0000, dengan hanya satu sampel salah klasifikasi dari 45.149 data uji. Seleksi fitur IG memangkas waktu pelatihan sebesar 52,7% tanpa penurunan akurasi. Uji statistik McNemar ($p = 0,4795$) menunjukkan bahwa perbedaan akurasi antara XGBoost dan *Random Forest* tidak signifikan secara statistik, namun XGBoost menunjukkan keunggulan komputasi yang substansial: waktu pelatihan $4,2\times$ lebih cepat dan latensi inferensi $3,9\times$ lebih rendah. Hasil ini mengindikasikan bahwa kombinasi XGBoost dan seleksi fitur IG merupakan pendekatan yang efektif dan efisien untuk deteksi DDoS pada jaringan kampus dengan keterbatasan sumber daya komputasi.

Index Terms—deteksi dan forensik DDoS; XGBoost; *information gain*; seleksi fitur; CIC-IDS2017; keamanan jaringan kampus; *intrusion detection system*; *machine learning*

I. PENDAHULUAN

Serangan *Distributed Denial of Service* (DDoS) merupakan salah satu ancaman keamanan siber yang paling prevalen dan merugikan secara global [1]. Laporan industri dari NETSCOUT mencatat peningkatan volume serangan DDoS secara konsisten setiap tahun [2], sementara Cloudflare melaporkan kenaikan serangan DDoS berbasis HTTP sebesar 65% dibandingkan periode sebelumnya [3]. Serangan ini bekerja dengan membanjiri sumber daya server target menggunakan trafik palsu dari sejumlah besar komputer penyerang, sehingga layanan menjadi tidak dapat diakses oleh pengguna yang sah.

Di lingkungan kampus, ancaman ini memiliki dimensi tersendiri. Jaringan kampus pada umumnya dirancang terbuka untuk mengakomodasi kebutuhan akses mahasiswa, dosen, dan staf. Kebijakan *Bring Your Own Device* (BYOD) yang memperbolehkan perangkat pribadi terhubung ke jaringan kampus turut memperluas permukaan serangan (*attack surface*) [4]. Kondisi ini menjadikan jaringan kampus rentan terhadap serangan DDoS, sementara keterbatasan staf TI dan spesifikasi perangkat keras membatasi kapasitas respons terhadap serangan yang terjadi secara mendadak [5].

Sistem deteksi intrusi (*Intrusion Detection System*/IDS) yang ada saat ini memiliki beberapa keterbatasan fundamental. Pertama, IDS berbasis pencocokan pola (*signature-based*) tidak mampu mendeteksi serangan DDoS yang belum terdaftar dalam basis data aturannya (*zero-day attacks*) [6]. Kedua, sejumlah pendekatan *machine learning* dalam penelitian terdahulu menggunakan seluruh himpunan fitur (hingga 78 fitur) tanpa melakukan seleksi fitur secara sistematis, sehingga mengakibatkan inefisiensi komputasi [7], [8]. Ketiga, sebagian besar penelitian berhenti pada tahap eksperimen dan belum menghasilkan prototipe aplikasi yang dapat dioperasikan secara langsung [9].

Untuk mengatasi kesenjangan tersebut, penelitian ini bertujuan untuk: (1) mengidentifikasi jumlah fitur optimal dari variasi $K = \{5, 10, 15, 20, 30, \text{all}\}$ menggunakan metode seleksi fitur *Information Gain*; (2) membandingkan performa algoritma XGBoost dan *Random Forest* pada jumlah fitur optimal tersebut; (3) mengembangkan aplikasi web DDoShield untuk deteksi dan forensik jaringan yang mampu menganalisis berkas .pcap secara langsung; dan (4) mengevaluasi performa aplikasi tersebut pada lingkungan operasional.

Kontribusi utama penelitian ini adalah sebagai berikut:

- 1) Analisis sistematis pengaruh seleksi fitur berbasis IG terhadap performa deteksi DDoS pada enam variasi nilai K , yang menunjukkan bahwa pengurangan 61,5% fitur tidak menurunkan akurasi.
- 2) Perbandingan komprehensif antara XGBoost dan *Random Forest* yang diperkuat dengan validasi 10 iterasi dan uji statistik McNemar.
- 3) Implementasi prototipe aplikasi web DDoShield yang mengintegrasikan deteksi hibrida (heuristik dan *machine learning*) dengan kemampuan forensik berbasis TreeSHAP [10].
- 4) Evaluasi performa sistem secara menyeluruh meliputi latensi, *throughput*, dan penggunaan sumber daya pada lingkungan server lokal.

Sisa paper ini disusun sebagai berikut: Seksi II memaparkan tinjauan pustaka; Seksi III menjelaskan metodologi penelitian; Seksi IV menyajikan hasil eksperimen dan analisis; Seksi V membahas temuan dan implikasinya; dan Seksi VI merangkum kesimpulan penelitian.

II. TINJAUAN PUSTAKA

A. Karakteristik Serangan DDoS

Serangan DDoS bekerja dengan menghabiskan kapasitas *bandwidth* jaringan atau membebani sumber daya server target menggunakan volume trafik yang sangat besar [11]. Trafik serangan umumnya dihasilkan secara simultan oleh jaringan komputer yang telah terinfeksi *malware*, yang dikenal sebagai *botnet* [6]. Secara taksonomi, serangan DDoS diklasifikasikan menjadi tiga kategori: (1) *volumetric attacks* yang bertujuan menjenuhkan *bandwidth*; (2) *protocol attacks* yang mengeksploitasi kelemahan protokol komunikasi; dan (3) *application layer attacks* yang menargetkan layanan aplikasi secara langsung [1].

B. Evolusi Sistem Deteksi Intrusi

IDS berbasis *machine learning* (ML) menawarkan pendekatan yang lebih adaptif dibandingkan metode *signature-based* konvensional, karena mampu mengidentifikasi anomali pada pola trafik tanpa memerlukan basis data aturan yang telah didefinisikan sebelumnya [11]. Berbagai algoritma ML telah dievaluasi untuk deteksi intrusi, antara lain *Decision Tree* [12], *Random Forest* [8], *Convolutional Neural Network* (CNN) [13], *Long Short-Term Memory* (LSTM) [14], dan *XGBoost* [15]. Studi survei terbaru oleh Ferrag et al. [16] mengonfirmasi bahwa metode *ensemble* berbasis pohon keputusan, termasuk *XGBoost*, secara konsisten menunjukkan performa superior pada dataset benchmark IDS.

C. XGBoost untuk Deteksi Intrusi

XGBoost (*eXtreme Gradient Boosting*) merupakan algoritma *ensemble learning* berbasis *gradient-boosted decision trees* yang dikenal karena kecepatan dan akurasi prediksi yang superior pada berbagai tugas klasifikasi [17]. Algoritma ini membangun pohon keputusan secara sekuensial, di mana setiap pohon baru bertugas meminimalkan *residual loss* dari estimator sebelumnya. Keunggulan utama *XGBoost* terletak pada mekanisme regularisasi bawaan (L_1 dan L_2) yang secara efektif mencegah *overfitting*, sehingga generalisasi model pada data baru tetap terjaga [17].

D. Information Gain untuk Seleksi Fitur

Information Gain (IG) mengukur kontribusi informatif suatu fitur dalam membedakan kelas target berdasarkan konsep entropi dari teori informasi Shannon [18]. Fitur dengan nilai IG tinggi memiliki daya diskriminasi yang kuat terhadap kelas DDoS dan BENIGN, sementara fitur dengan IG mendekati nol dianggap tidak informatif. Metode seleksi fitur berbasis IG memungkinkan eliminasi fitur-fitur yang redundan, sehingga kompleksitas komputasi dapat direduksi tanpa mengorbankan akurasi klasifikasi [19].

Tabel 1 merangkum perbandingan penelitian terkait. Analisis terhadap studi-studi tersebut mengungkapkan dua kesenjangan riset: (1) mayoritas penelitian menggunakan seluruh fitur tanpa eksplorasi sistematis terhadap jumlah fitur optimal, dan (2) tidak menyediakan prototipe aplikasi yang siap dioperasikan. Penelitian ini bertujuan mengisi kedua kesenjangan tersebut.

III. METODOLOGI

Penelitian ini merupakan eksperimen komputasional yang bertujuan membangun model deteksi DDoS berbasis *machine learning* dan mengimplementasikannya ke dalam prototipe aplikasi web forensik. Secara keseluruhan, metodologi dilaksanakan melalui sembilan tahapan: (1) persiapan dataset, (2) *preprocessing*, (3) pembagian data, (4) seleksi fitur, (5) *hyperparameter tuning* *XGBoost*, (6) pelatihan dan evaluasi *XGBoost*, (7) pelatihan dan evaluasi *Random Forest*, (8) uji statistik McNemar, dan (9) implementasi dan pengujian aplikasi DDoShield. Seluruh komputasi dilakukan pada komputer berspesifikasi Intel Core i7 dengan RAM 16 GB menggunakan Python 3.14, Scikit-learn 1.8, *XGBoost* 3.2, dan Scapy 2.7. Reprodusibilitas dijamin melalui penggunaan `random_state = 42`.

A. Dataset Penelitian

Dataset yang digunakan adalah CIC-IDS2017, dikembangkan oleh *Canadian Institute for Cybersecurity* [21]. Dataset ini merupakan salah satu *benchmark* yang paling banyak digunakan dalam penelitian deteksi intrusi [20], menyediakan data *flow-based* yang sesuai dengan pendekatan yang digunakan dalam penelitian ini. Secara spesifik, berkas `Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv` digunakan, yang berisi 225.745 sampel dengan rincian 128.027 sampel serangan DDoS (56,7%) dan 97.718 sampel lalu lintas normal berlabel BENIGN (43,3%). Setiap sampel memiliki 78 fitur numerik hasil ekstraksi *CICFlowMeter*, meliputi statistik aliran seperti durasi, jumlah paket, panjang paket, dan berbagai metrik turunan lainnya. Meskipun dataset ini merupakan standar yang banyak digunakan, perlu dicatat bahwa beberapa keterbatasan telah diidentifikasi oleh Engelen et al. [22], termasuk adanya anomali pada distribusi kelas tertentu.

B. Preprocessing Data

Tahap *preprocessing* dilakukan melalui serangkaian langkah untuk memastikan kualitas data:

- 1) *Filtering Label*: Data difilter untuk menyisakan hanya sampel dengan label DDoS dan BENIGN, sesuai dengan fokus klasifikasi biner dalam penelitian ini.
- 2) *Penanganan Nilai Tak Hingga*: Nilai $\pm\infty$ yang dihasilkan oleh pembagian dengan nol pada proses ekstraksi *CICFlowMeter* dikonversi menjadi NaN.
- 3) *Penghapusan Fitur*: Fitur dengan proporsi nilai kosong melebihi 50% dieliminasi dari dataset karena dianggap tidak reliabel.
- 4) *Imputasi Data*: Nilai kosong pada fitur yang tersisa diisi menggunakan nilai median. Statistik median dipilih karena ketahanannya (*robustness*) terhadap nilai pencilan (*outliers*), sebagaimana direkomendasikan untuk data jaringan yang sering mengandung anomali ekstrem [23].
- 5) *Normalisasi*: Seluruh fitur numerik dinormalisasi menggunakan *StandardScaler* (Scikit-learn) sehingga memiliki rata-rata 0 dan standar deviasi 1.

Tabel I
PERBANDINGAN PENELITIAN TERKAIT DETEKSI INTRUSI BERBASIS ML

Ref.	Dataset	Algoritma	Metode Deteksi	Akurasi	K (Fitur)	Aplikasi
[15]	CIC-IDS2017	XGBoost+Corr	Flow-based	99,5%	all (78)	Tidak
[7]	UNSW-NB15	XGBoost+IG	Flow-based	99,2%	10	Tidak
[8]	CIC-IDS2017	Random Forest	Flow-based	98,7%	20	Tidak
[13]	CIC-IDS2017	CNN	Packet-based	99,1%	all	Tidak
[14]	CIC-IDS2017	LSTM	Packet-based	98,3%	all	Tidak
[20]	CIC-IDS2017	Multi-algo	Flow-based	–	–	Tidak
[9]	Review	Multi-algo	–	–	–	Tidak
Kami	CIC-IDS2017	XGB+IG	Flow-based	≈100%	30	Ya

C. Pembagian Data

Dataset dibagi menjadi data latih dan data uji dengan rasio 80:20 menggunakan *stratified random sampling* untuk mempertahankan proporsi kelas. Data latih berjumlah 180.596 sampel dan data uji 45.149 sampel.

Meskipun pembagian acak pada data *time-series* berpotensi menimbulkan *data leakage*, protokol ini dipertahankan agar performa dapat dibandingkan secara setara dengan penelitian terdahulu yang menggunakan metode serupa pada CIC-IDS2017 [7], [8], [15].

Untuk menguji stabilitas hasil, seluruh proses diulang sebanyak 10 kali menggunakan 10 *random seed* yang berbeda (10x *repeated random sub-sampling validation*). Performa yang dilaporkan merupakan rata-rata dan simpangan baku ($\mu \pm \sigma$) dari 10 iterasi tersebut.

D. Seleksi Fitur Menggunakan Information Gain

Seleksi fitur dilakukan menggunakan IG untuk mengukur kontribusi setiap fitur dalam membedakan kelas DDoS dan BENIGN. Secara matematis, IG mengukur reduksi entropi ketika suatu fitur diketahui nilainya [18]. Fitur dengan IG tinggi memiliki daya diskriminasi yang kuat, sedangkan fitur dengan IG mendekati nol dianggap tidak informatif [19].

Perhitungan skor IG dilakukan menggunakan fungsi *mutual_info_classif* (Scikit-learn). Pemilihan fitur optimal dilakukan melalui *SelectKBest* dengan variasi $K = \{5, 10, 15, 20, 30, \text{all (78)}\}$. Rentang nilai K ini dipilih untuk mencakup spektrum dari jumlah fitur yang sangat terbatas (5) hingga himpunan penuh (78), dengan interval yang memungkinkan visualisasi kurva performa yang representatif. Seleksi fitur dilakukan hanya pada data latih untuk menghindari kebocoran informasi.

E. Hyperparameter Tuning XGBoost

Pencarian parameter optimal dilakukan menggunakan *RandomizedSearchCV* (Scikit-learn) dengan 20 iterasi dan *5-fold cross-validation*, menggunakan F1-Score (*macro average*) sebagai metrik evaluasi.

Ruang parameter yang dieksplorasi meliputi: *n_estimators*, *max_depth*, *learning_rate*, *subsample*, *colsample_bytree*, dan *scale_pos_weight*. Konfigurasi optimal yang diperoleh adalah: *n_estimators* = 300, *max_depth* = 4, *learning_rate* = 0,2, *subsample* = 0,7,

colsample_bytree = 0,8, dan *scale_pos_weight* = 0,7633.

F. Pelatihan dan Evaluasi Model XGBoost

Model XGBoost dilatih menggunakan konfigurasi optimal untuk setiap nilai K , menghasilkan enam model yang dievaluasi pada data uji yang sama. Metrik evaluasi yang digunakan meliputi:

- **Accuracy**: Persentase prediksi benar dari keseluruhan data uji.
- **Precision**: Proporsi prediksi DDoS yang benar, mengukur kemampuan meminimalkan *false positive*.
- **Recall**: Proporsi data DDoS yang berhasil dideteksi, mengukur kemampuan meminimalkan *false negative*.
- **F1-Score**: Rata-rata harmonik Precision dan Recall, menjadi metrik utama.
- **AUC-ROC**: Area di bawah kurva ROC.
- **Training Time** dan **Inference Time**: Efisiensi komputasi.

G. Model Pembandingan Random Forest

Sebagai pembandingan, digunakan *Random Forest* (RF) yang merupakan salah satu algoritma *ensemble* yang populer dalam deteksi intrusi [8]. RF dilatih menggunakan data dan fitur yang sama ($K = 30$ dan $K = \text{all}$) dengan konfigurasi: *n_estimators* = 200, *max_features* = 'sqrt', dan *class_weight* = 'balanced' [8].

H. Uji Statistik McNemar

Signifikansi perbedaan performa antara XGBoost dan RF diuji menggunakan uji McNemar, yaitu uji non-parametrik untuk membandingkan dua model klasifikasi pada dataset yang sama. Hipotesis yang diuji:

- H_0 : Tidak ada perbedaan signifikan antara akurasi kedua model
- H_1 : Terdapat perbedaan signifikan antara akurasi kedua model

Dengan ambang signifikansi $\alpha = 0,05$, H_0 ditolak jika $p\text{-value} < 0,05$.

I. Implementasi Aplikasi DDoShield

Model optimal (XGBoost, $K = 30$) diintegrasikan ke dalam aplikasi web DDoShield, yang dikembangkan menggunakan kerangka kerja Flask (Python) dengan arsitektur tiga lapis (*presentation*, *application*, dan *data*).

Aplikasi mendukung dua mode operasional:

- 1) *Analisis Offline*: Pengunggahan berkas .pcap/.csv untuk ekstraksi aliran, klasifikasi, dan visualisasi hasil deteksi.
- 2) *Live Sniffing*: Penangkapan paket secara langsung dari antarmuka jaringan menggunakan Scapy.

a) *Ekstraksi Aliran*.: Berkas .pcap dibaca menggunakan Scapy, di mana paket dikelompokkan menjadi aliran (*flow*) berdasarkan 5-tuple: alamat IP sumber, alamat IP tujuan, port sumber, port tujuan, dan protokol.

b) *Mesin Deteksi Hibrida*.: DDoShield menerapkan pendekatan deteksi hibrida yang menggabungkan aturan heuristik dan klasifikasi ML:

a. *Aturan Heuristik*: Sebelum pemrosesan oleh model ML, aliran disaring oleh *Heuristics Engine* untuk mendeteksi serangan amplifikasi. Ambang batas (*threshold*) volume 50 paket diterapkan pada port-port layanan yang rentan terhadap serangan amplifikasi: DNS (Port 53), NTP (Port 123), SSDP (Port 1900), dan Memcached (Port 11211). Nilai *threshold* ini ditetapkan secara konservatif berdasarkan observasi bahwa trafik normal pada port-port tersebut jarang melebihi puluhan paket per aliran dalam kondisi operasional [1], dan bertujuan mengatasi *generalization gap* pada pola serangan yang telah dikenal.

b. *Pipeline Machine Learning*: Aliran yang tidak memicu aturan heuristik diproses melalui *pipeline* Scikit-learn:

- SimpleImputer (imputer.pkl): Imputasi nilai kosong dengan median.
- StandardScaler (scaler.pkl): Normalisasi skala data.
- SelectKBest (selector_kopt.pkl): Seleksi 30 fitur optimal.
- XGBoost Classifier (xgb_model_kopt.pkl): Klasifikasi akhir.

Skema deteksi hibrida ini diformalisasikan pada Algoritma 1.

Algorithm 1 Skema Deteksi Hibrida DDoShield

Require: Berkas Capture Jaringan P (.pcap atau .csv)
Ensure: Hasil Deteksi Aliran D (BENIGN atau DDoS)

```

1:  $F \leftarrow \text{EkstraksiFlow}(P)$  {Mengelompokkan paket berdasarkan 5-tuple}
2: for setiap aliran  $f \in F$  do
3:    $\text{is\_heur}, \text{label} \leftarrow \text{PeriksaAturanHeuristik}(f)$ 
4:   if  $\text{is\_heur} = \text{True}$  then
5:      $D(f) \leftarrow \text{label}$  {DNS/NTP/SSDP/Memcached Amplification}
6:   else
7:      $f_{\text{imputed}} \leftarrow \text{ImputasiNilaiTengah}(f)$  {SimpleImputer}
8:      $f_{\text{scaled}} \leftarrow \text{StandarisasiSkala}(f_{\text{imputed}})$  {StandardScaler}
9:      $f_{K30} \leftarrow \text{SeleksiFitur}(f_{\text{scaled}}, K = 30)$  {SelectKBest}
10:     $\text{skor\_pred} \leftarrow \text{XGBoostClassifier}(f_{K30})$ 
11:    if  $\text{skor\_pred} = 1$  then
12:       $D(f) \leftarrow \text{"DDoS (XGBoost)"}$ 
13:    else
14:       $D(f) \leftarrow \text{"BENIGN"}$ 
15:    end if
16:  end if
17: end for
18: return  $D$ 

```

Seluruh model dan objek *pipeline* disimpan dalam format .pkl pada direktori lokal untuk operasi *offline* tanpa koneksi internet, sehingga privasi data trafik kampus terjaga.

c) *Fitur Forensik Berbasis TreeSHAP*.: DDoShield dilengkapi kemampuan *Explainable AI* menggunakan TreeSHAP [10], [24]. Ketika pengguna memilih aliran mencurigakan pada dasbor, sistem menghitung dan memvisualisasikan lima fitur dominan yang melatarbelakangi keputusan klasifikasi. Pendekatan ini sejalan dengan rekomendasi Mahbooba et al. [25] mengenai pentingnya transparansi model untuk meningkatkan kepercayaan operator terhadap sistem IDS.

d) *Pengujian Aplikasi*.: Pengujian DDoShield dilakukan pada lingkungan lokal:

- *Pengujian Fungsional*: Verifikasi kemampuan ekstraksi aliran, klasifikasi, dan visualisasi forensik menggunakan berkas .pcap dengan *ground truth* yang diketahui, dibandingkan dengan analisis Wireshark.
- *Pengujian Performa*: Evaluasi latensi, *throughput*, dan penggunaan sumber daya menggunakan tiga ukuran berkas (100, 1.000, dan 10.000 flow).


IV. HASIL DAN ANALISIS

A. Performa XGBoost per Variasi K


Tabel II menyajikan hasil evaluasi klasifikasi XGBoost pada berbagai nilai K . Evaluasi dilakukan secara terisolasi pada modul ML (tanpa *Heuristic Engine*) menggunakan pembagian data 80/20.

Pada $K = 5$, model telah mencapai F1-Score 99,89%, namun performa ini merupakan yang terendah relatif terhadap variasi K lainnya, sebagaimana divisualisasikan pada Gambar 2. Performa meningkat secara monoton seiring penambahan fitur, hingga mencapai titik optimal pada $K = 30$ dengan F1-Score 99,9977%. Hasil menunjukkan bahwa model dengan $K = 30$ fitur mencapai performa yang setara secara statistik dengan model yang menggunakan seluruh 78 fitur, mengindikasikan adanya redundansi substansial pada 48 fitur yang dieliminasi [7], [26].

Gambar 1 menyajikan peringkat 30 fitur teratas berdasarkan skor IG. Fitur dengan daya diskriminasi tertinggi meliputi *Total Length of Fwd Packets* (IG=0,652), *Subflow Fwd Bytes* (IG=0,652), *Average Packet Size* (IG=0,563), dan *Destination Port* (IG=0,542). Dominansi fitur-fitur yang berkaitan dengan volume dan ukuran paket ini konsisten dengan karakteristik serangan DDoS jenis *flooding* [21].



Gambar 1. Top-30 Fitur Berdasarkan Skor *Information Gain*.



Gambar 2. F1-Score XGBoost terhadap Variasi Nilai K .

B. Pengaruh IG terhadap Efisiensi Komputasi

Reduksi jumlah fitur dari 78 menjadi $K = 30$ menghasilkan penurunan waktu pelatihan sebesar **52,7%** (dari 9,38 s menjadi 4,44 s) tanpa degradasi akurasi. Temuan ini signifikan dalam

Tabel II
PERFORMA XGBOOST PER VARIASI K PADA DATASET CIC-IDS2017

K	Accuracy (%)	Prec. (%)	Recall (%)	F1-Score (%)	AUC-ROC	Training (s)	Infer. (ms/flow)
5	99,88	≥99,8	≥99,8	99,89	0,9999	5,54	0,003
10	99,94	≥99,9	≥99,9	99,95	1,0000	3,41	0,002
15	99,96	≥99,9	≥99,9	99,96	1,0000	3,59	0,002
20	99,98	≥99,9	≥99,9	99,98	1,0000	3,88	0,003
30 *	99,9978	100,00	99,9961	99,9977	1,0000	4,44	0,005
all (78)	99,9978	100,00	99,9961	99,9977	1,0000	9,38	0,005

* = K optimal; Prec./Recall macro-average.


konteks penerapan di lingkungan kampus, di mana keterbatasan sumber daya komputasi merupakan kendala operasional yang umum [17].

C. Perbandingan XGBoost vs. Random Forest


Tabel III menyajikan perbandingan performa XGBoost dan RF pada $K = 30$, berdasarkan rata-rata 10 iterasi. Gambar 3 menampilkan *confusion matrix* kedua model, sementara Gambar 4 memvisualisasikan kurva ROC komparatif.

Tabel III
PERBANDINGAN XGBOOST VS. RANDOM FOREST (K=30, RATA-RATA 10 ITERASI)

Metrik	XGBoost	Random Forest
Accuracy (%)	99,9971 ± 0,0017	99,9916 ± 0,0026
Precision-DDoS (%)	99,9969 ± 0,0019	99,9909 ± 0,0028
Recall-DDoS (%)	99,9972 ± 0,0017	99,9919 ± 0,0026
F1-Score / macro (%)	99,9971 ± 0,0018	99,9914 ± 0,0026
AUC-ROC	99,9998 ± 0,0003	99,9987 ± 0,0014
Training Time (s)	4,14 ± 0,16	17,43 ± 0,21
Inference (ms/flow)	0,0012 ± 0,0001	0,0047 ± 0,0006



Gambar 3. Confusion Matrix XGBoost (kiri) vs. RF (kanan) pada K=30.



Gambar 4. Kurva ROC XGBoost vs. Random Forest (K=30).

Hasil validasi 10 iterasi menunjukkan bahwa performa XGBoost sangat stabil dengan simpangan baku $\pm 0,0018\%$ pada F1-Score. XGBoost secara konsisten mengungguli RF pada seluruh metrik evaluasi. Perbedaan performa yang paling signifikan diamati pada efisiensi komputasi: XGBoost mencapai reduksi waktu pelatihan $4,2\times$ (4,14 s vs 17,43 s) dan peningkatan *throughput* inferensi $3,9\times$ (0,0012 ms vs 0,0047 ms per flow).

Konsistensi hasil lintas 10 iterasi mengonfirmasi bahwa keunggulan XGBoost bukan merupakan artefak dari satu kali pembagian data, melainkan refleksi dari kapabilitas arsitektur

gradient boosting dalam memodelkan batas keputusan *non-linear* pada dataset CIC-IDS2017.

Bandingkan dengan penelitian terkait pada Tabel I, akurasi model yang diajukan melampaui Thakkar dan Lohiya [15] (99,5%), Kasongo dan Sun [7] (99,2%), dan RF oleh Ullah dan Mahmoud [8] (98,7%).

D. Hasil Pengujian DDoShield

Tabel V menyajikan hasil evaluasi performa aplikasi DDoShield pada lingkungan server lokal. Aplikasi mampu memproses berkas .pcap berukuran kecil (100 flow) dengan latensi 6,08 ms, berukuran sedang (1.000 flow) dalam 8,89 ms, dan berukuran besar (10.000 flow) dalam 56,69 ms. *Model throughput* mencapai 112.512,52 flow/detik. Penggunaan sumber daya pada kondisi *idle* tercatat 152,9 MB RAM dan 17,1% CPU, meningkat menjadi 430,6 MB RAM dan 61,0% CPU saat memproses 1.000 flow. Nilai *False Positive Rate* sebesar 0,00% mengindikasikan tidak adanya kesalahan klasifikasi pada data normal.

Pengujian fungsional menggunakan berkas .pcap berisi jejak serangan mengonfirmasi bahwa DDoShield mampu mengelompokkan paket mentah menjadi aliran terstruktur dan melabeli aliran serangan secara tepat. Visualisasi TreeSHAP pada dashboard berhasil mengidentifikasi fitur Flow Packets/s dan Fwd Packet Length sebagai fitur dominan pada aliran DDoS, konsisten dengan analisis manual menggunakan Wireshark.

Berdasarkan temuan kuantitatif yang telah dipaparkan, seksi berikut mendiskusikan interpretasi, implikasi praktis, perbandingan dengan literatur, serta keterbatasan penelitian.

V. PEMBAHASAN

A. Interpretasi Temuan Utama

Performa klasifikasi XGBoost yang mendekati 100% dapat diatribusikan kepada mekanisme koreksi kesalahan iteratif yang inheren pada arsitektur *gradient boosting*, di mana setiap estimator berikutnya meminimalkan *residual loss* dari estimator sebelumnya [17]. Mekanisme regularisasi bawaan (L_1 dan L_2) turut berkontribusi dalam mencegah *overfitting* [15]. Temuan ini sejalan dengan hasil yang dilaporkan oleh sejumlah peneliti lain pada dataset CIC-IDS2017 [20], [22], yang menunjukkan bahwa distribusi statistik kelas pada dataset ini memang memiliki separabilitas yang tinggi.

Tabel IV
PERBANDINGAN VALIDASI DDoSHIELD DENGAN APLIKASI JARINGAN UMUM

Kriteria	DDoShield (Kami)	Wireshark	Snort
Metode Analisis	Machine Learning	Inspeksi Manual	Aturan Statis (<i>Signature</i>)
Validitas Hasil	Sangat Tinggi (Berdasarkan Dataset)	Standar Acuan Utama	Bergantung <i>Update</i> Aturan
Deteksi Serangan Baru	Bisa (Melihat Pola Anomali)	Bisa (Tergantung Analisis)	Tidak Bisa
Kecepatan Deteksi	Sangat Cepat (0,0051 ms/flow)	Lambat (Manual)	Cepat (Otomatis)
Cara Analisis (Forensik)	Grafik Visual (<i>TreeSHAP</i>)	Baca Kode <i>Hex/Bytes</i>	Baca Teks Peringatan (<i>Alert</i>)

Tabel V
HASIL PENGUJIAN PERFORMA DDoSHIELD

Metrik	Nilai	Satuan	Kondisi
Latensi (100 flow)	6,08	ms	.pcap kecil
Latensi (1000 flow)	8,89	ms	.pcap sedang
Latensi (10000 flow)	56,69	ms	.pcap besar
Throughput	112.512,52	flow/s	.pcap sedang
CPU idle	17,1	%	Server idle
CPU aktif	61,0	%	1000 flow
Memory idle	152,9	MB	Server idle
Memory aktif	430,6	MB	1000 flow
FPR (BENIGN only)	0,00	%	100% normal

B. Implikasi Praktis untuk Kampus

Dengan latensi inferensi sebesar 0,0051 ms per flow, DDoShield secara arsitektural memungkinkan untuk diintegrasikan pada infrastruktur jaringan kampus, misalnya melalui mekanisme *port mirroring* pada router, sebagaimana diuraikan pada Seksi I. Namun demikian, validasi lebih lanjut dalam lingkungan produksi diperlukan untuk mengonfirmasi kelayakan operasional. Ketersediaan REST API pada DDoShield juga memfasilitasi integrasi dengan sistem pemantauan keamanan yang telah ada.

C. Validasi dan Keunggulan Dibandingkan Aplikasi Lain

Untuk memvalidasi kebenaran fungsional DDoShield, dilakukan perbandingan dengan dua aplikasi jaringan yang telah mapan: **Wireshark** dan **Snort**. Wireshark berfungsi sebagai standar acuan (*ground truth*) karena kemampuannya menampilkan isi paket secara langsung, namun analisis manual terhadap ratusan ribu paket memerlukan waktu yang signifikan dan rentan terhadap kesalahan manusia. Snort sebagai IDS *signature-based* menawarkan deteksi otomatis yang cepat, namun terbatas pada pola serangan yang telah didefinisikan sebelumnya.

Sebagaimana ditunjukkan pada Tabel IV, DDoShield menggunakan klasifikasi berbasis statistik aliran (*flow statistics*), yang secara prinsip lebih adaptif terhadap variasi serangan baru dibandingkan pendekatan *signature-based* [6]. Namun, validasi empiris terhadap serangan *zero-day* berada di luar cakupan penelitian ini dan menjadi salah satu arah penelitian mendatang. Untuk keperluan forensik, DDoShield menyediakan visualisasi *TreeSHAP* yang mengidentifikasi fitur pemicu klasifikasi DDoS secara langsung, menghilangkan kebutuhan analisis *byte* heksadesimal paket secara manual [24].

D. Keterbatasan

Penelitian ini memiliki beberapa keterbatasan: (1) evaluasi dilakukan pada dataset CIC-IDS2017 yang bersifat simulasi dan memiliki keterbatasan yang telah didokumentasikan [22], [26]; (2) meskipun mendukung mode *Live Sniffing*, evaluasi performa difokuskan pada analisis berkas .pcap (*offline*); (3) pengujian terbatas pada satu server lokal; dan (4) model belum dievaluasi terhadap serangan adversarial pada ruang fitur yang dirancang untuk mengelabui IDS berbasis ML [27].

E. Arah Penelitian Mendatang

Penelitian selanjutnya diarahkan pada: (1) pengumpulan dan evaluasi menggunakan data trafik kampus aktual; (2) pengembangan sistem deteksi *real-time* dari trafik langsung (*live capture*); (3) evaluasi ketahanan model terhadap serangan adversarial; dan (4) eksplorasi metode pembaruan model secara inkremental (*continual learning*).

VI. KESIMPULAN

Penelitian ini telah mengembangkan dan mengevaluasi sistem deteksi DDoS berbasis XGBoost dengan seleksi fitur *Information Gain*, serta mengimplementasikannya ke dalam prototipe aplikasi web DDoShield.

Pada pengujian stabilitas 10 iterasi, model XGBoost dengan $K = 30$ fitur optimal mempertahankan rata-rata *F1-Score* sebesar 99,9971% ($\pm 0,0018\%$) dan AUC-ROC sebesar 99,9998%. Performa ini konsisten unggul dibandingkan *Random Forest* (*F1-Score* 99,9914%). Seleksi fitur IG terbukti efektif mereduksi waktu pelatihan sebesar 52,7% tanpa degradasi akurasi. Secara komputasi, XGBoost menunjukkan efisiensi yang superior dengan reduksi waktu pelatihan $4,2\times$ dan peningkatan *throughput* inferensi $3,9\times$ dibandingkan RF.

Hasil ini mengonfirmasi bahwa kombinasi XGBoost dan seleksi fitur IG merupakan pendekatan yang efektif untuk deteksi DDoS pada jaringan kampus dengan keterbatasan sumber daya komputasi. Penelitian mendatang akan difokuskan pada validasi menggunakan trafik kampus aktual secara langsung.

REFERENSI

- [1] A. Singh and B. B. Gupta, "Distributed denial-of-service (DDoS) attacks and defense mechanisms in various web-enabled computing platforms: Issues, challenges, and future research directions," *Int. J. Inf. Secur.*, vol. 21, pp. 1–22, 2022.
- [2] NETSCOUT Systems, "NETSCOUT threat intelligence report," NETSCOUT Systems, Inc., Westford, MA, USA, Industry Report, 2023, [Online]. Available: <https://www.netscout.com/threatreport>. [Accessed: 15-Mar-2025].
- [3] Cloudflare, "DDoS threat report Q3 2023," Cloudflare, Inc., San Francisco, CA, USA, Industry Report, 2023, [Online]. Available: <https://blog.cloudflare.com/ddos-threat-report-2023-q3>. [Accessed: 15-Mar-2025].
- [4] G. B. A. Mthunzi, M. O. Adigun, and J. A. Ojo, "Adoption of BYOD in higher education: Security vulnerabilities and solutions," *Int. J. Comput. Theory Eng.*, vol. 12, no. 3, pp. 78–84, 2020.
- [5] M. N. Al-Mhiqani, R. Ahmad, and Z. Z. Abidin, "Cyber security challenges in higher education institutions: A systematic review," *Int. J. Adv. Comput. Sci. Appl.*, vol. 11, no. 7, pp. 125–135, 2020.
- [6] M. Ring, S. Wunderlich, D. Scheuring, D. Landes, and A. Hotho, "A survey of network-based intrusion detection data sets," *Comput. Secur.*, vol. 86, pp. 147–167, 2019.
- [7] S. M. Kasongo and Y. Sun, "Performance analysis of intrusion detection systems using a feature selection method on the UNSW-NB15 dataset," *J. Big Data*, vol. 7, no. 1, pp. 1–20, 2020.
- [8] I. Ullah and Q. H. Mahmoud, "A two-level flow-based anomalous activity detection system for IoT networks," *Electronics*, vol. 9, no. 3, p. 530, 2020.
- [9] O. H. Abdulganiyu, T. A. Tchakoucht, and Y. K. Saheed, "A systematic literature review for network intrusion detection system (IDS)," *Int. J. Inf. Secur.*, vol. 22, pp. 1125–1162, 2023.
- [10] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017, [Online]. Available: <https://arxiv.org/abs/1705.07874>
- [11] V. Chandola, A. Banerjee, and V. Kumar, "Anomaly detection: A survey," *ACM Comput. Surv.*, vol. 41, no. 3, pp. 1–58, 2009.
- [12] A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, "Survey of intrusion detection systems: Techniques, datasets and challenges," *Cybersecurity*, vol. 2, no. 1, p. 20, 2019.
- [13] R. Vinayakumar, M. Alazab, K. P. Soman, P. Poornachandran, A. Al-Nemrat, and S. Venkatraman, "Deep learning approach for intelligent intrusion detection system," *IEEE Access*, vol. 7, pp. 41 525–41 550, 2019.
- [14] R. Vinayakumar, K. P. Soman, and P. Poornachandran, "Applying convolutional neural network for network intrusion detection," in *Proc. Int. Conf. Advances in Computing, Communications and Informatics (ICACCI)*, 2017, pp. 1222–1228.
- [15] A. Thakkar and R. Lohiya, "A review of the advancement in intrusion detection datasets," *Procedia Comput. Sci.*, vol. 167, pp. 636–645, 2020.
- [16] M. A. Ferrag, L. Maglaras, S. Moschoyannis, and H. Janicke, "Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study," *J. Inf. Secur. Appl.*, vol. 68, p. 103228, 2022.
- [17] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," in *Proc. 22nd ACM SIGKDD Int. Conf. Knowl. Discov. Data Min. (KDD)*, San Francisco, CA, USA, Aug. 2016, pp. 785–794.
- [18] C. E. Shannon, "A mathematical theory of communication," *Bell Syst. Tech. J.*, vol. 27, no. 3, pp. 379–423, 1948.
- [19] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *J. Mach. Learn. Res.*, vol. 3, pp. 1157–1182, 2003.
- [20] J. L. Leevy and T. M. Khoshgoftaar, "A survey and analysis of intrusion detection models based on CIC-IDS2017 dataset," *J. Big Data*, vol. 7, no. 1, p. 104, 2020.
- [21] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward generating a new intrusion detection dataset and intrusion traffic characterization," in *Proc. 4th Int. Conf. Inf. Syst. Security Privacy (ICISSP)*, 2018, pp. 108–116.
- [22] G. Engelen, V. Rimmer, and W. Joosen, "Troubleshooting an intrusion detection dataset: the CICIDS2017 case study," in *Proc. IEEE Security Privacy Workshops (SPW)*, 2021, pp. 7–12.
- [23] W.-C. Lin, S.-W. Ke, and C.-F. Tsai, "CANN: An intrusion detection system based on combining cluster centers and nearest neighbors," *Knowl.-Based Syst.*, vol. 78, pp. 13–21, 2015.
- [24] S. M. Lundberg, G. Erion, H. Chen, A. DeGrave, J. M. Prutkin, B. Nair, R. Katz, J. Himmelfarb, N. Bansal, and S.-I. Lee, "From local explanations to global understanding with explainable AI for trees," *Nat. Mach. Intell.*, vol. 2, no. 1, pp. 56–67, 2020.
- [25] B. Mahbooba, M. Timilsina, R. Sahal, and M. Serrano, "Explainable artificial intelligence (XAI) to enhance trust management in intrusion detection systems using decision tree model," *Complexity*, vol. 2021, p. 6634811, 2021.
- [26] M. Sarhan, S. Layeghy, and M. Portmann, "Towards a standard feature set for network intrusion detection system datasets," *Mobile Netw. Appl.*, vol. 27, no. 1, pp. 357–370, 2022.
- [27] M. N. Alenezi and M. J. Alhajri, "Tackling imbalanced data in cybersecurity with transfer and ensemble learning: A survey," *IEEE Access*, vol. 12, pp. 18 162–18 197, 2024.