

Pengembangan Perangkat Lunak Deteksi dan Forensik Jaringan DDoS Berbasis XGBoost dan Information Gain

Falito Eriano Nainggolan, Dimas Surya Pratama, Gita Olivia Silaban

Program Studi Rekayasa Keamanan Siber

Politeknik Siber dan Sandi Negara, Bogor, Indonesia

Email: falito.eriano@poltekssn.ac.id, dimas.surya@poltekssn.ac.id, gita.olivia@poltekssn.ac.id

Ringkasan—Serangan *Distributed Denial of Service* (DDoS) merupakan salah satu ancaman utama bagi keamanan jaringan di lingkungan kampus. Kampus biasanya memiliki jaringan yang terbuka karena banyak mahasiswa dan staf yang menghubungkan perangkat pribadi mereka secara bebas. Sayangnya, sistem pendeteksi dan analisis forensik serangan DDoS yang ringan, akurat, dan mudah digunakan langsung di kampus masih sangat terbatas. Oleh karena itu, dalam penelitian ini kami mengembangkan DDoShield, sebuah perangkat lunak web untuk deteksi dan forensik jaringan DDoS menggunakan algoritma XGBoost dan seleksi fitur *Information Gain* (IG). Eksperimen kami dilakukan menggunakan dataset standar CIC-IDS2017 (225.745 sampel data dan 78 fitur). Kami menguji performa model dengan variasi jumlah fitur $K = \{5, 10, 15, 20, 30, \text{all}\}$ dan membandingkan XGBoost dengan algoritma *Random Forest* menggunakan uji statistik McNemar. Hasil eksperimen menunjukkan bahwa XGBoost dengan $K = 30$ fitur terbaik mampu mencapai *F1-Score* sebesar 99,9977% dan nilai AUC-ROC sebesar 1,0000. Dari 45.149 data uji, model kami hanya salah menebak 1 sampel saja. Seleksi fitur IG berhasil memangkas waktu pelatihan sebesar 52,7% (dari 9,38s menjadi 4,44s) tanpa mengurangi akurasi. Selanjutnya, perbandingan antara XGBoost dan *Random Forest* pada $K=30$ menggunakan uji statistik McNemar ($p = 0,4795$) menunjukkan bahwa akurasi keduanya tidak berbeda secara signifikan, namun XGBoost jauh lebih unggul dalam kecepatan komputasi: waktu pelatihan $6,9\times$ lebih cepat dan waktu deteksi per flow $1,6\times$ lebih cepat (0,0051 ms vs. 0,0084 ms/flow). Hasil ini membuktikan bahwa kombinasi XGBoost dan seleksi fitur IG sangat cocok dan efisien untuk analisis forensik dan deteksi DDoS di jaringan kampus yang memiliki keterbatasan spesifikasi komputer server.

Index Terms—deteksi dan forensik DDoS; XGBoost; *information gain*; seleksi fitur; CIC-IDS2017; keamanan jaringan kampus; *intrusion detection system*; *machine learning*

I. PENDAHULUAN

Serangan *Distributed Denial of Service* (DDoS) merupakan salah satu masalah keamanan komputer yang paling sering terjadi dan merugikan di dunia. Berdasarkan laporan keamanan dari NETSCOUT, jumlah serangan DDoS terus meningkat setiap tahunnya [1]. Laporan dari Cloudflare juga menyebutkan bahwa serangan DDoS berbasis web (HTTP) naik sebesar 65% dibanding tahun sebelumnya [2]. Serangan ini bekerja dengan cara membanjiri komputer server menggunakan trafik palsu dari banyak komputer penyerang, sehingga pengguna asli kesulitan atau bahkan tidak bisa mengakses layanan web tersebut.

Di lingkungan kampus, masalah keamanan ini menjadi tantangan tersendiri. Jaringan kampus biasanya dirancang terbuka untuk memudahkan mahasiswa, dosen, dan staf mengakses internet atau layanan akademik. Selain itu, adanya kebijakan *Bring Your Own Device* (BYOD) membuat siapa saja bisa menghubungkan laptop atau ponsel pribadi mereka ke jaringan kampus [3]. Hal ini membuat jaringan kampus menjadi sasaran yang mudah diserang malware. Di sisi lain, tim TI di kampus sering kali memiliki keterbatasan jumlah staf dan spesifikasi perangkat keras untuk menangani serangan DDoS yang mendadak [4].

Selama ini, sistem pendeteksi penyusupan (*Intrusion Detection System* atau IDS) yang digunakan masih memiliki beberapa kelemahan. Pertama, IDS tradisional yang memakai sistem pencocokan pola (*signature-based*) tidak bisa mendeteksi jenis serangan DDoS baru yang belum terdaftar di database mereka (serangan *zero-day*) [5]. Kedua, banyak metode *machine learning* yang diusulkan dalam penelitian sebelumnya langsung memakai semua fitur data (bisa sampai 78 fitur) tanpa mencari tahu fitur mana yang sebenarnya paling penting [6], [7]. Hal ini membuat pemrosesan data menjadi lambat dan berat. Ketiga, jarang ada penelitian akademis yang membuat aplikasinya sampai jadi dan bisa langsung dicoba secara nyata oleh pengguna [8].

Untuk mengatasi masalah tersebut, dalam penelitian ini kami bertujuan untuk: (1) mencari tahu berapa jumlah fitur terbaik (dari variasi $K = \{5, 10, 15, 20, 30, \text{all}\}$) menggunakan metode seleksi fitur *Information Gain*; (2) membandingkan performa algoritma XGBoost dan *Random Forest* pada jumlah fitur terbaik tersebut; (3) membuat aplikasi web DDoShield untuk deteksi dan forensik jaringan yang bisa menganalisis file trafik .pcap secara langsung; dan (4) menguji performa aplikasi tersebut secara riil.

Penelitian ini diharapkan dapat memberikan kontribusi berupa: (1) analisis sistematis pemilihan fitur terbaik untuk deteksi dan forensik DDoS; (2) perbandingan performa XGBoost dan *Random Forest* yang diperkuat dengan uji statistik McNemar; (3) *software* deteksi dan forensik jaringan (DDoShield) yang siap pakai; dan (4) hasil pengukuran kinerja sistem yang nyata pada lingkungan lokal.

Sisa paper ini disusun sebagai berikut: Seksi II menjelaskan tinjauan pustaka; Seksi III membahas metode penelitian kami;

Seksi IV memaparkan hasil eksperimen dan analisis; Seksi V membahas temuan penelitian; dan Seksi VI menyimpulkan hasil penelitian kami.

II. TINJAUAN PUSTAKA

A. Karakteristik Serangan DDoS pada Jaringan Kampus

Serangan DDoS bekerja dengan cara menghabiskan kapasitas *bandwidth* jaringan atau membebani sumber daya komputer server target menggunakan trafik yang sangat besar [9]. Trafik ini biasanya dikirim secara bersamaan oleh banyak komputer yang telah terinfeksi *malware* (biasa disebut *botnet*) [5]. Secara umum, serangan DDoS dibagi menjadi tiga kelompok utama: (1) *volumetric attacks* yang bertujuan menghabiskan *bandwidth* internet; (2) *protocol attacks* yang memanfaatkan celah pada aturan protokol komunikasi data; dan (3) *application layer attacks* yang menyerang langsung aplikasi atau layanan web server yang sedang berjalan.

B. Evolusi Sistem Deteksi Intrusi

Untuk mendeteksi serangan ini, sistem pendeteksi penyusupan (IDS) berbasis *machine learning* (ML) menawarkan solusi yang lebih pintar. Dibandingkan dengan metode biasa yang kaku, metode ML bisa mengenali tanda-tanda aneh pada trafik jaringan secara otomatis tanpa perlu memiliki daftar tanda serangan (*signature*) terlebih dahulu [9]. Beberapa algoritma ML yang sering digunakan untuk tugas ini antara lain *Decision Tree* [10], *Random Forest* [7], *Convolutional Neural Network* (CNN) [11], *Long Short-Term Memory* (LSTM) [12], dan *XGBoost* [13].

C. XGBoost untuk Deteksi Intrusi

XGBoost (*eXtreme Gradient Boosting*) adalah algoritma pembelajaran mesin berbasis pohon keputusan (*decision tree*) yang sangat populer karena kecepatan dan akurasi yang tinggi [14]. Algoritma ini bekerja dengan cara membangun banyak pohon keputusan secara berurutan, di mana setiap pohon baru bertugas memperbaiki kesalahan tebakan dari pohon-pohon sebelumnya. Keunggulan utama XGBoost adalah kemampuannya untuk mencegah model agar tidak terlalu menghafal data secara berlebihan (*overfitting*) menggunakan fungsi pembatas (*regularization*) bawaan, sehingga performa model tetap stabil saat menguji data baru [14].

D. Information Gain untuk Seleksi Fitur

Information Gain (IG) adalah metode yang kami gunakan untuk mengukur seberapa penting atau berharganya informasi dari suatu fitur dalam menentukan apakah suatu lalu lintas jaringan merupakan serangan DDoS atau trafik normal (*BENIGN*) [15]. Konsep dasar IG berfokus pada tingkat ketidakpastian data (*entropy*). Fitur yang memiliki nilai IG tinggi berarti mengandung informasi yang sangat kuat untuk membedakan antara trafik normal dan serangan. Sebaliknya, fitur dengan nilai IG mendekati nol dianggap tidak penting. Dengan menggunakan metode seleksi fitur berbasis IG ini, kami dapat membuang fitur-fitur yang tidak relevan sehingga model bisa bekerja jauh lebih cepat dan ringan saat dijalankan di server [16].

E. Dataset CIC-IDS2017

Dalam penelitian ini, kami menggunakan dataset CIC-IDS2017 yang dibuat oleh *Canadian Institute for Cybersecurity* (CIC) [17]. Dataset ini berisi rekaman trafik jaringan normal dan berbagai jenis serangan selama lima hari kerja. Rekaman trafik tersebut kemudian diproses menggunakan program *CICFlowMeter* sehingga menghasilkan 78 fitur berbasis flow. Kami menggunakan file data khusus bernama *Friday-WorkingHours-Afternoon-DDos.pcap_ISCX.csv* yang berisi 225.745 baris data, dengan rincian 128.027 data serangan DDoS (56,7%) dan 97.718 data normal (*BENIGN*) (43,3%).

Tabel I
PERBANDINGAN PENELITIAN TERKAIT

Ref.	Dataset	Algoritma	Acc.	K
[13]	CIC-IDS	XGBoost+Corr	99,5%	all
[6]	UNSW	XGBoost+IG	99,2%	10
[7]	CIC-IDS	RF	98,7%	20
[11]	CIC-IDS	CNN	99,1%	all
[12]	CICIDS	LSTM	98,3%	all
[8]	Review	Multi-algo	—	—
Kami	CIC-IDS	XGB+IG	≈100%	30

III. METODOLOGI

Penelitian ini merupakan eksperimen komputasional yang bertujuan membangun model deteksi DDoS berbasis *machine learning* dan mengimplementasikannya ke dalam prototipe aplikasi web forensik. Secara keseluruhan, penelitian dilakukan melalui sembilan tahapan yang disusun secara kronologis, yaitu: (1) pemilihan dan persiapan dataset, (2) pembersihan data (*preprocessing*), (3) pembagian data latih dan data uji, (4) seleksi fitur menggunakan *Information Gain*, (5) pencarian parameter optimal (*hyperparameter tuning*) XGBoost, (6) pelatihan dan evaluasi model XGBoost, (7) pelatihan dan evaluasi model pembandingan *Random Forest*, (8) perbandingan performa kedua model menggunakan uji statistik *McNemar*, dan (9) implementasi model terbaik ke dalam aplikasi web DDoShield serta pengujian fungsional dan performa sistem. Seluruh proses komputasi dijalankan pada komputer berspesifikasi Intel Core i7 dengan RAM 16GB dan sistem operasi Windows. Lingkungan perangkat lunak yang digunakan adalah Python 3.14, Scikit-learn 1.8, XGBoost 3.2, dan Scapy 2.7. Seluruh pembagian data dan pengacakan dalam eksperimen ini menggunakan `random_state = 42` untuk menjamin reproduktibilitas hasil.

A. Dataset Penelitian

Dataset yang digunakan dalam penelitian ini adalah CIC-IDS2017 yang dikembangkan oleh *Canadian Institute for Cybersecurity* (CIC) [17]. Dataset ini dipilih karena merupakan salah satu dataset standar yang paling banyak digunakan dalam penelitian deteksi intrusi, memiliki variasi serangan yang lengkap, dan menyediakan data *flow-based* yang sesuai dengan pendekatan yang kami gunakan. Secara spesifik, penelitian ini

menggunakan berkas `Friday-WorkingHours-Afternoon-DDoS.pcap_ISCX.csv` yang berisi rekaman lalu lintas jaringan pada hari Jumat sore yang didominasi oleh serangan DDoS. Berkas ini terdiri dari 225.745 sampel data dengan rincian 128.027 sampel serangan DDoS (56,7%) dan 97.718 sampel lalu lintas normal berlabel BENIGN (43,3%). Setiap sampel memiliki 78 fitur numerik hasil ekstraksi menggunakan CICFlowMeter, yang mencakup statistik aliran seperti durasi, jumlah paket, panjang paket, dan berbagai metrik turunan lainnya.

B. Preprocessing Data

Tahap pembersihan data (*preprocessing*) dilakukan melalui serangkaian langkah yang teratur untuk memastikan kualitas data sebelum digunakan dalam pelatihan model. Langkah-langkah tersebut adalah sebagai berikut:

- 1) *Filtering Label*: Data difilter untuk hanya menyisakan baris dengan label DDoS dan BENIGN, karena kedua kelas inilah yang menjadi fokus klasifikasi biner dalam penelitian ini. Kelas lain seperti serangan selain DDoS tidak digunakan agar model yang dihasilkan bersifat spesifik untuk deteksi DDoS.
- 2) *Penanganan Nilai Tak Hingga*: Nilai tak hingga ($\pm\infty$) yang muncul akibat pembagian dengan nol pada proses ekstraksi CICFlowMeter diubah menjadi nilai kosong (*Not a Number* atau NaN) untuk memudahkan proses penanganan data kosong selanjutnya.
- 3) *Penghapusan Fitur dengan Banyak Data Kosong*: Fitur yang memiliki proporsi data kosong lebih dari 50% dihapus dari dataset. Hal ini dilakukan karena fitur dengan banyak nilai hilang dianggap tidak reliabel dan dapat menurunkan kualitas model jika dipertahankan.
- 4) *Imputasi Data Kosong*: Nilai kosong yang tersisa pada fitur-fitur lainnya diisi menggunakan nilai median dari kolom fitur tersebut. Median dipilih karena statistik ini lebih tangguh (*robust*) terhadap anomali ekstrem dibandingkan rata-rata, sehingga lebih cocok untuk data lalu lintas jaringan yang sering mengandung nilai pencilan (*outliers*).
- 5) *Normalisasi Data*: Seluruh fitur numerik dinormalisasi menggunakan `StandardScaler` dari pustaka Scikit-learn. Proses ini mengubah setiap fitur sehingga memiliki nilai rata-rata 0 dan standar deviasi 1, yang bertujuan menyamakan skala antar fitur agar tidak ada fitur dengan rentang nilai besar yang mendominasi proses pembelajaran model.

C. Pembagian Data

Setelah tahap *preprocessing* selesai, dataset dibagi menjadi dua subset, yaitu data latih (*training set*) dan data uji (*testing set*), dengan rasio 80:20. Pembagian dilakukan menggunakan metode *stratified random sampling* untuk memastikan proporsi kelas DDoS dan BENIGN pada kedua subset tetap seimbang dan merepresentasikan distribusi kelas pada dataset asli. Dengan demikian, data latih berjumlah 180.596 sampel dan data uji berjumlah 45.149 sampel.

Perlu dicatat bahwa meskipun pembagian acak pada data deret waktu (*time-series*) berpotensi menimbulkan kebocoran data (*data leakage*) karena urutan waktu tidak diperhatikan, protokol ini tetap kami pertahankan. Keputusan ini diambil agar performa model dapat dibandingkan secara setara dengan penelitian-penelitian terdahulu yang umumnya menggunakan metode serupa pada dataset CIC-IDS2017 [6], [7], [13].

Untuk menguji stabilitas varians hasil eksperimen, seluruh proses pembagian data, pelatihan, dan evaluasi model diulang sebanyak 10 kali menggunakan 10 *random seed* yang berbeda (*10x repeated random sub-sampling validation*). Hasil performa yang dilaporkan pada penelitian ini merupakan rata-rata dan simpangan baku ($\mu \pm \sigma$) dari 10 iterasi tersebut.

D. Seleksi Fitur Menggunakan Information Gain

Seleksi fitur dilakukan menggunakan metode Information Gain (IG) yang bertujuan mengukur seberapa penting kontribusi setiap fitur dalam membedakan kelas DDoS dan BENIGN. Secara matematis, IG mengukur pengurangan entropi (ketidakpastian) ketika suatu fitur diketahui nilainya, sesuai dengan teori informasi yang dikemukakan oleh Shannon [15]. Fitur dengan nilai IG tinggi memiliki kemampuan diskriminasi yang kuat, sedangkan fitur dengan nilai IG mendekati nol dianggap tidak informatif dan dapat dibuang [16].

Perhitungan skor IG dilakukan menggunakan fungsi `mutual_info_classif` dari pustaka Scikit-learn, yang secara matematis menghitung *Mutual Information* antara setiap fitur dan target kelas. Setelah skor IG diperoleh untuk seluruh 78 fitur, pemilihan fitur terbaik dilakukan menggunakan fungsi `SelectKBest` dengan variasi jumlah fitur $K = \{5, 10, 15, 20, 30, \text{all (78)}\}$. Variasi ini diterapkan untuk mengidentifikasi jumlah fitur optimal yang memberikan kinerja terbaik dengan kompleksitas komputasi paling rendah. Proses seleksi fitur dilakukan setelah data dibagi menjadi data latih dan data uji, di mana perhitungan IG hanya dilakukan pada data latih untuk menghindari kebocoran informasi dari data uji.

E. Hyperparameter Tuning XGBoost

Untuk memperoleh model XGBoost dengan performa optimal, dilakukan pencarian parameter terbaik (*hyperparameter tuning*) menggunakan metode `RandomizedSearchCV` dari pustaka Scikit-learn. Metode ini dipilih karena lebih efisien dibandingkan `GridSearchCV` untuk ruang pencarian yang luas, karena hanya melakukan pencarian pada sejumlah sampel parameter yang dipilih secara acak.

Proses tuning dilakukan dengan ketentuan sebagai berikut:

- Jumlah percobaan: 20 kali iterasi
- Metode validasi: *5-fold cross-validation*
- Metrik evaluasi: F1-Score (*macro average*)
- Ruang parameter yang dicari meliputi: `n_estimators` (jumlah pohon keputusan), `max_depth` (kedalaman pohon), `learning_rate` (laju pembelajaran), `subsample` (proporsi sampel yang digunakan per pohon), `colsample_bytree` (proporsi fitur yang digu-

nakan per pohon), dan `scale_pos_weight` (penyeimbang bobot kelas).

Parameter terbaik yang diperoleh dari proses tuning adalah: `n_estimators = 300`, `max_depth = 4`, `learning_rate = 0,2`, `subsample = 0,7`, `colsample_bytree = 0,8`, dan `scale_pos_weight = 0,7633`. Parameter-parameter ini kemudian digunakan untuk melatih model XGBoost final pada seluruh data latih.

F. Pelatihan dan Evaluasi Model XGBoost

Model XGBoost dilatih menggunakan konfigurasi parameter terbaik yang diperoleh dari tahap *tuning* pada data latih yang telah melalui seleksi fitur untuk setiap nilai K . Proses ini menghasilkan enam model XGBoost yang berbeda, masing-masing sesuai dengan jumlah fitur $K = \{5, 10, 15, 20, 30, \text{all}\}$. Setiap model dievaluasi pada data uji yang sama untuk mengukur kinerjanya secara objektif.

Metrik evaluasi yang digunakan meliputi:

- **Akurasi (Accuracy):** Persentase prediksi benar dari keseluruhan data uji.
- **Presisi (Precision):** Proporsi prediksi DDoS yang benar terhadap seluruh prediksi DDoS, mengukur kemampuan model dalam meminimalkan *false positive*.
- **Recall:** Proporsi data DDoS yang berhasil dideteksi dengan benar, mengukur kemampuan model dalam meminimalkan *false negative*.
- **F1-Score:** Rata-rata harmonik dari Presisi dan Recall, yang menjadi metrik acuan utama karena memberikan evaluasi yang lebih komprehensif dibandingkan akurasi saja, terutama pada data dengan ketidakseimbangan kelas.
- **False Positive Rate (FPR):** Persentase data normal yang salah terdeteksi sebagai DDoS.
- **AUC-ROC:** Area di bawah kurva ROC yang mengukur kemampuan model dalam membedakan kedua kelas secara keseluruhan.
- **Waktu Pelatihan (Training Time):** Waktu yang dibutuhkan untuk melatih model, diukur dalam detik.
- **Waktu Inferensi (Inference Time):** Waktu yang dibutuhkan untuk memprediksi satu aliran data, diukur dalam mili-detik per *flow*.

G. Model Pembandingan Random Forest

Sebagai pembandingan, digunakan algoritma Random Forest (RF) yang merupakan salah satu metode *ensemble learning* berbasis pohon keputusan yang populer dalam deteksi intrusi [7]. Random Forest dilatih menggunakan data dan fitur yang sama dengan XGBoost (pada $K = 30$ dan $K = \text{all}$) agar perbandingan performa bersifat adil.

Konfigurasi Random Forest yang digunakan adalah sebagai berikut:

- `n_estimators = 200` (jumlah pohon keputusan)
- `max_features = 'sqrt'` (jumlah fitur yang dipertimbangkan untuk setiap pembagian pohon)
- `class_weight = 'balanced'` (menyeimbangkan bobot kelas secara otomatis)

Parameter-parameter ini dipilih berdasarkan konfigurasi standar yang umum digunakan dalam penelitian deteksi intrusi [7], sehingga hasil yang diperoleh dapat dibandingkan dengan penelitian terdahulu.

H. Uji Statistik McNemar

Untuk mengetahui apakah perbedaan performa antara XGBoost dan Random Forest signifikan secara statistik, dilakukan uji McNemar. Uji ini merupakan uji non-parametrik yang digunakan untuk membandingkan dua model klasifikasi pada dataset yang sama dengan melihat konsistensi prediksi kedua model pada setiap sampel data uji. Hipotesis yang diuji adalah:

- H_0 : Tidak ada perbedaan signifikan antara akurasi XGBoost dan Random Forest
- H_1 : Terdapat perbedaan signifikan antara akurasi XGBoost dan Random Forest

Uji McNemar menghasilkan nilai statistik χ^2 dan nilai- p (p -value). Jika p -value $< 0,05$, maka H_0 ditolak, yang berarti kedua model memiliki performa yang berbeda secara signifikan. Sebaliknya, jika p -value $\geq 0,05$, maka H_0 diterima, yang berarti perbedaan performa kedua model tidak signifikan secara statistik.

I. Implementasi Aplikasi DDoShield

Model terbaik yang diperoleh dari tahap eksperimen (XGBoost dengan $K = 30$) kemudian diintegrasikan ke dalam aplikasi web DDoShield. Aplikasi ini dikembangkan menggunakan kerangka kerja Flask di Python dengan arsitektur modular tiga lapis (*presentation*, *application*, dan *data*). Tujuan implementasi ini adalah untuk menyediakan alat deteksi dan forensik DDoS yang ringan, akurat, dan mudah digunakan oleh administrator jaringan kampus.

Aplikasi DDoShield mendukung dua mode operasional:

- 1) **Analisis Offline:** Pengguna mengunggah berkas tangkapan jaringan dalam format `.pcap` atau `.csv`, kemudian aplikasi melakukan ekstraksi aliran, klasifikasi, dan menampilkan hasil deteksi pada dasbor web.
- 2) **Penangkapan Paket Real-Time (Live Sniffing):** Aplikasi menangkap paket secara langsung dari antarmuka jaringan menggunakan pustaka Scapy untuk durasi tertentu, kemudian melakukan analisis secara langsung.

a) **Ekstraksi Aliran.:** Berkas `.pcap` yang diunggah dibaca menggunakan Scapy, di mana paket-paket data dikelompokkan menjadi aliran (*flow*) berdasarkan kombinasi 5-tuple: alamat IP sumber, alamat IP tujuan, port sumber, port tujuan, dan protokol. Waktu kedatangan paket dikonversi ke tipe data *float* untuk menghindari kesalahan komputasi saat menghitung statistik durasi aliran dan jeda kedatangan paket (*Flow IAT*).

b) **Mesin Deteksi Hibrida.:** DDoShield menerapkan pendekatan deteksi hibrida yang menggabungkan aturan heuristik dan klasifikasi *machine learning*:

a. **Aturan Heuristik:** Sebelum data diproses oleh model *machine learning*, aliran data disaring oleh *Heuristics Engine* untuk mendeteksi serangan amplifikasi yang memiliki pola trafik khas. Aturan ini menerapkan batas ambang (*threshold*)

volume paket pada port-port layanan yang sering digunakan untuk serangan amplifikasi, yaitu DNS (Port 53), NTP (Port 123), SSDP (Port 1900), dan Memcached (Port 11211). Jika sebuah aliran memiliki lebih dari 50 paket pada port-port tersebut, aliran langsung diklasifikasikan sebagai serangan DDoS amplifikasi. Pendekatan hibrida ini bertujuan mengatasi keterbatasan data latih (*generalization gap*) dan mempercepat deteksi untuk serangan dengan pola yang sudah sangat dikenal.

b. Pipeline Machine Learning: Aliran yang tidak memicu aturan heuristik diproses melalui *pipeline* Scikit-learn yang terdiri dari:

- SimpleImputer (imputer.pkl): Mengisi nilai kosong/NaN dengan median dari data latih.
- StandardScaler (scaler.pkl): Menormalisasi skala data numerik.
- SelectKBest (selector_kopt.pkl): Memilih 30 fitur terbaik berdasarkan skor Information Gain.
- XGBoost Classifier (xgb_model_kopt.pkl): Melakukan klasifikasi akhir (DDoS atau BENIGN).

Skema deteksi hibrida ini diformalisasikan pada Algoritma 1.

Algorithm 1 Skema Deteksi Hibrida DDoShield

Require: Berkas Capture Jaringan P (.pcap atau .csv)

Ensure: Hasil Deteksi Aliran D (BENIGN atau DDoS)

```

1:  $F \leftarrow \text{EkstraksiFlow}(P)$  {Mengelompokkan paket berdasarkan 5-tuple}
2: for setiap aliran  $f \in F$  do
3:    $\text{is\_heur, label} \leftarrow \text{PeriksaAturanHeuristik}(f)$ 
4:   if  $\text{is\_heur} = \text{True}$  then
5:      $D(f) \leftarrow \text{label}$  {DNS/NTP/SSDP/Memcached Amplification}
6:   else
7:      $f_{\text{imputed}} \leftarrow \text{ImputasiNilaiTengah}(f)$  {SimpleImputer}
8:      $f_{\text{scaled}} \leftarrow \text{StandarisasiSkala}(f_{\text{imputed}})$  {StandardScaler}
9:      $f_{K30} \leftarrow \text{SeleksiFitur}(f_{\text{scaled}}, K = 30)$  {SelectKBest}
10:     $\text{skor\_pred} \leftarrow \text{XGBoostClassifier}(f_{K30})$ 
11:    if  $\text{skor\_pred} = 1$  then
12:       $D(f) \leftarrow \text{"DDoS (XGBoost)"}$ 
13:    else
14:       $D(f) \leftarrow \text{"BENIGN"}$ 
15:    end if
16:  end if
17: end for
18: return  $D$ 

```

Seluruh model dan objek *pipeline* disimpan dalam format berkas serialisasi `.pkl` pada direktori lokal aplikasi agar dapat dijalankan secara *offline* tanpa memerlukan koneksi internet, sehingga menjaga privasi data lalu lintas jaringan kampus.

c) *Fitur Forensik Berbasis TreeSHAP*.: Sebagai instrumen investigasi forensik, DDoShield dilengkapi dengan kemampuan *Explainable AI* menggunakan algoritma TreeSHAP [18]. Setiap kali pengguna mengklik baris aliran yang mencurigakan pada dasbor web, sistem memanggil REST API untuk menghitung dan memvisualisasikan 5 fitur dominan yang melatarbelakangi keputusan klasifikasi DDoS. Analisis ini memberikan konteks forensik instan kepada administrator untuk mengidentifikasi anatomi serangan tanpa perlu mengisolasi *payload* paket secara manual (*Deep Packet Inspection*).

d) *Pengujian Aplikasi.*: Pengujian DDoShield dilakukan pada lingkungan lokal dengan skenario sebagai berikut:

- *Pengujian Fungsional*: Aplikasi diuji menggunakan berkas .pcap yang telah diketahui isinya (mengandung

jejak serangan DDoS) untuk memverifikasi kemampuan ekstraksi aliran, klasifikasi, dan visualisasi forensik. Hasil deteksi dibandingkan dengan analisis manual menggunakan Wireshark sebagai *ground truth*.

- **Pengujian Performa:** Aplikasi diuji menggunakan tiga ukuran berkas .pcap (100 flow, 1.000 flow, dan 10.000 flow) untuk mengukur latensi pemrosesan, *throughput* model, penggunaan CPU, dan penggunaan memori RAM. Pengukuran dilakukan dalam kondisi server idle dan saat memproses data.


IV. HASIL DAN ANALISIS

A. Performa XGBoost per Variasi K


Tabel II menunjukkan hasil evaluasi performa klasifikasi untuk model XGBoost murni pada berbagai jumlah fitur K. Pengujian ini dilakukan secara spesifik pada modul *Machine Learning* (tanpa pelibatan saringan *Heuristic Engine*) menggunakan pembagian data latih-uji 80/20 untuk mengukur kapabilitas algoritmanya secara terisolasi.

Pada K=5, model sudah menghasilkan *FI-Score* sebesar 99,89%, yang mana sudah sangat bagus tetapi merupakan yang terendah dibanding pilihan K lainnya, sebagaimana ditunjukkan pada Gambar 2. Akurasi terus naik seiring bertambahnya fitur, hingga mencapai performa tertinggi pada K=30 (*FI-Score* 100,00% atau tepatnya 99,9977%). Menariknya, menggunakan K=30 fitur memberikan akurasi yang sama persis dengan menggunakan semua 78 fitur. Hal ini membuktikan bahwa 48 fitur lainnya tidak terlalu dibutuhkan karena informasinya tumpang tindih (*redundan*) dengan fitur yang sudah terpilih [6].

Berdasarkan hasil IG pada Gambar 1, fitur-fitur yang paling membantu model dalam mendeteksi DDoS adalah *Total Length of Fwd Packets* (IG=0,652), *Subflow Fwd Bytes* (IG=0,652), *Average Packet Size* (IG=0,563), dan *Destination Port* (IG=0,542). Fitur-fitur ini menunjukkan ukuran dan jumlah paket data yang dikirim, yang memang sangat mencerminkan pola serangan DDoS jenis *flooding* (membanjiri trafik) [17].



Gambar 1. Top-30 Fitur Berdasarkan Skor *Information Gain*.



Gambar 2. F1-Score XGBoost terhadap Variasi Nilai K.

B. Pengaruh IG terhadap Efisiensi Komputasi

Dengan mengurangi jumlah fitur dari 78 menjadi $K=30$, kami berhasil mempercepat waktu pelatihan (*training time*) sebesar **52,7%** (dari 9,38 s menjadi 4,44 s) tanpa mengurangi akurasi sama sekali. Hal ini sangat penting karena melatih model dengan sedikit fitur membutuhkan memori dan daya komputasi komputer server yang lebih kecil [14].

Tabel II
PERFORMA XGBOOST PER VARIASI K PADA DATASET CIC-IDS2017

K	Accuracy (%)	Prec. (%)	Recall (%)	F1-Score (%)	AUC-ROC	Training (s)	Infer. (ms/flow)
5	99,88	≥99,8	≥99,8	99,89	0,9999	5,54	0,003
10	99,94	≥99,9	≥99,9	99,95	1,0000	3,41	0,002
15	99,96	≥99,9	≥99,9	99,96	1,0000	3,59	0,002
20	99,98	≥99,9	≥99,9	99,98	1,0000	3,88	0,003
30 *	99,9978	100,00	99,9961	99,9977	1,0000	4,44	0,005
all (78)	99,9978	100,00	99,9961	99,9977	1,0000	9,38	0,005


* = K optimal; Prec./Recall macro-average.

C. Perbandingan XGBoost vs. Random Forest

Tabel III menunjukkan perbandingan performa antara XGBoost dan *Random Forest* pada K=30.

Tabel III
PERBANDINGAN XGBOOST VS. RANDOM FOREST (K=30, RATA-RATA 10 ITERASI)

Metrik	XGBoost	Random Forest
Accuracy (%)	99,9971 ± 0,0017	99,9916 ± 0,0026
Precision-DDoS (%)	99,9969 ± 0,0019	99,9909 ± 0,0028
Recall-DDoS (%)	99,9972 ± 0,0017	99,9919 ± 0,0026
F1-Score / macro (%)	99,9971 ± 0,0018	99,9914 ± 0,0026
AUC-ROC	99,9998 ± 0,0003	99,9987 ± 0,0014
Training Time (s)	4,14 ± 0,16	17,43 ± 0,21
Inference (ms/flow)	0,0012 ± 0,0001	0,0047 ± 0,0006



Gambar 3. Confusion Matrix XGBoost (kiri) vs. RF (kanan) pada K=30.

Gambar 4. Kurva ROC XGBoost vs. Random Forest (K=30).

Dari hasil pengujian stabilitas menggunakan 10 iterasi (*10x repeated random sub-sampling validation*) tersebut, terlihat bahwa performa XGBoost sangat stabil dengan simpangan baku yang sangat kecil ($\pm 0,0018\%$ pada F1-Score). XGBoost juga terbukti secara konsisten mengungguli *Random Forest* di semua metrik evaluasi. Rata-rata akurasi XGBoost mencapai 99,9971%, dibandingkan RF sebesar 99,9916%. Perbedaan performa terbesar ada pada waktu komputasi: XGBoost melatih data $4,2\times$ lebih cepat (4,14 s vs 17,43 s) dan memproses satu *flow* data hampir $4\times$ lebih cepat (0,0012 ms vs 0,0047 ms).

Berdasarkan stabilitas hasil ini, perbedaan performa yang sangat konsisten membuktikan bahwa keunggulan XGBoost bukanlah sebuah kebetulan matematis akibat *data leakage* pada satu kali pembagian acak, melainkan karena arsitekturnya yang lebih andal untuk memodelkan batas keputusan *non-linear* yang kompleks pada dataset CIC-IDS2017.

Dibandingkan dengan penelitian terkait yang ditunjukkan pada Tabel I, akurasi XGBoost kami melampaui Thakkar dan Lohiya [13] (99,5%) dan Kasongo dan Sun [6] (99,2%), serta melampaui RF yang dilaporkan Ullah dan Mahmoud [7] (98,7%).

D. Hasil Pengujian DDoShield

Tabel IV menunjukkan hasil uji performa aplikasi DDoShield saat kami coba mengunggah file .pcap secara langsung ke server lokal kami.

Tabel IV
HASIL PENGUJIAN PERFORMA DDOSHIELD

Metrik	Nilai	Satuan	Kondisi
Latensi (100 flow)	6,08	ms	.pcap kecil
Latensi (1000 flow)	8,89	ms	.pcap sedang
Latensi (10000 flow)	56,69	ms	.pcap besar
Throughput	112.512,52	flow/s	.pcap sedang
CPU idle	17,1	%	Server idle
CPU aktif	61,0	%	1000 flow
Memory idle	152,9	MB	Server idle
Memory aktif	430,6	MB	1000 flow
FPR (BENIGN only)	0,00	%	100% normal

Aplikasi DDoShield dapat menganalisis file .pcap kecil (100 flow) dengan waktu latensi hanya 6,08 ms, pcap sedang (1.000 flow) dalam 8,89 ms, dan pcap besar (10.000 flow) dalam 56,69 ms. Kecepatan pemrosesan inferensi *backend* (*model throughput*) mencapai puncak di angka 112.512,52 flow per detik (angka ini adalah kecepatan prediksi model di memori, tidak termasuk waktu tunggu ekstraksi *parsing* PCAP oleh Scapy). Saat server dalam kondisi diam (*idle*), memori RAM yang digunakan adalah 152,9 MB dengan beban CPU 17,1%. Ketika memproses file dengan 1.000 flow, memori RAM naik menjadi 430,6 MB dan beban CPU menjadi 61,0%. Hasil *False Positive Rate* (FPR) adalah 0,00%, yang menunjukkan bahwa aplikasi ini tidak salah mendeteksi data normal sebagai serangan.

Sebagai bukti validitas fungsional (*functional testing*), kami menguji aplikasi ini secara langsung menggunakan sampel berkas .pcap yang memuat jejak serangan jaringan. DDoShield terbukti mampu mengelompokkan paket-paket mentah menjadi aliran terstruktur (*flows*) secara otomatis dan berhasil melabeli aliran serangan secara tepat. Fitur forensik visual *TreeSHAP* pada dasbor DDoShield juga berhasil menyoroti anomali pada fitur Flow Packets/s dan Fwd Packet

Length sebagai pemicu vonis DDoS. Temuan ini konsisten dengan hasil analisis manual yang kami lakukan menggunakan Wireshark pada berkas yang sama. Hal ini menjadi bukti bahwa mekanisme *parsing* PCAP dan inferensi XGBoost dalam aplikasi DDoShield berjalan dengan benar dan dapat diandalkan.

V. PEMBAHASAN

A. Interpretasi Temuan Utama

Keberhasilan model XGBoost dalam mendeteksi DDoS dengan F1-Score mendekati 100% dikarenakan cara kerja algoritma *gradient boosting* yang memperbaiki kesalahan tebakan model sebelumnya di setiap pohon keputusan baru [14]. Selain itu, teknik regularisasi yang ada pada XGBoost juga sangat membantu mencegah model agar tidak terlalu menghafal data latih (*overfitting*) [13]. Akurasi yang sangat tinggi ini juga dilaporkan oleh peneliti lain pada dataset CIC-IDS2017 [19] karena kelas data pada dataset ini memang memiliki pola trafik yang sangat jelas dibedakan secara statistik.

B. Implikasi Praktis untuk Kampus

Karena proses pendeteksian XGBoost sangat cepat (0,0051 ms per flow), aplikasi DDoShield ini dapat diintegrasikan langsung pada router kampus untuk menganalisis salinan trafik (*port mirroring*) secara berkala. Aplikasi ini juga dilengkapi dengan REST API sehingga bisa dihubungkan ke sistem pemantauan keamanan lain yang sudah ada di kampus.

C. Validasi dan Keunggulan Dibandingkan Aplikasi Lain

Untuk memastikan program DDoShield berjalan dengan benar dan hasilnya valid, kami membandingkannya dengan dua aplikasi jaringan yang sudah umum digunakan, yaitu **Wireshark** dan **Snort**. Wireshark sering dijadikan standar acuan (*ground truth*) karena mampu menampilkan isi paket jaringan secara langsung. Namun, menganalisis ratusan ribu paket DDoS di Wireshark secara manual tentu membutuhkan waktu lama dan rawan terjadi kesalahan. Sementara itu, Snort adalah aplikasi pendeteksi penyusupan (IDS) yang cepat, tetapi karena berbasis aturan statis (*signature-based*), ia sering kesulitan mendeteksi serangan tipe baru (*zero-day*) yang belum ada aturannya.

DDoShield hadir untuk menutupi kekurangan kedua aplikasi tersebut. Seperti yang ditunjukkan pada Tabel V, DDoShield memberikan akurasi pendeteksian yang valid dengan waktu proses yang jauh lebih efisien dibandingkan analisis manual Wireshark. Berbeda dengan Snort yang kaku pada aturan, model XGBoost pada DDoShield berpotensi mengenali varian serangan yang belum memiliki *signature* karena klasifikasinya berbasis pola statistik aliran (*flow statistics*), bukan pencocokan teks paket. Meskipun demikian, kemampuan ini belum diuji secara eksplisit pada serangan *zero-day* dalam penelitian ini. Selain itu, untuk keperluan forensik, DDoShield menyediakan grafik *TreeSHAP* yang langsung menampilkan fitur penyebab serangan. Hal ini memudahkan pengguna untuk melakukan evaluasi tanpa harus menganalisis kode *byte heksadesimal*

paket yang rumit seperti di Wireshark. Dengan demikian, program ini tidak hanya akurat secara komputasi, tetapi juga mudah dan praktis digunakan.

D. Keterbatasan

Adapun beberapa keterbatasan ruang lingkup dalam penelitian ini meliputi: (1) penggunaan dataset standar CIC-IDS2017 sebagai representasi trafik simulasi [19]; (2) meskipun DDoShield mendukung mode *Live Sniffing*, evaluasi performa pada penelitian ini difokuskan pada mode analisis berkas *.pcap* rekaman (*offline capture*); (3) uji coba performa aplikasi yang dibatasi pada satu komputer server lokal; dan (4) model belum dievaluasi terhadap jenis serangan siber terbaru yang menggunakan teknik manipulasi data (*adversarial attacks*).

E. Arah Penelitian Mendatang

Untuk penelitian selanjutnya, kami berencana untuk: (1) mengumpulkan data trafik langsung dari jaringan kampus kami; (2) mengembangkan sistem deteksi *real-time* dari trafik jaringan yang mengalir langsung (*live capture*); (3) menguji ketahanan model terhadap serangan yang dimanipulasi; dan (4) mencoba metode pembaruan model secara otomatis agar tetap akurat seiring berjalannya waktu (*continual learning*).

VI. KESIMPULAN

Dalam penelitian ini, kami telah mengembangkan dan mengevaluasi sistem deteksi DDoS berbasis XGBoost dengan seleksi fitur *Information Gain*. Kami juga membuat prototipe aplikasi web bernama DDoShield untuk membantu mendeteksi serangan di jaringan kampus secara lebih mudah.

Pada pengujian stabilitas 10 iterasi, model XGBoost dengan $K = 30$ fitur terbaik berhasil mempertahankan rata-rata *F1-Score* sebesar 99,9971% ($\pm 0,0018\%$) dan nilai AUC-ROC sebesar 99,9998%. Hasil ini sangat stabil dan konsisten sedikit lebih baik dibandingkan dengan *Random Forest* yang memperoleh *F1-Score* 99,9914%. Metode seleksi fitur IG terbukti sangat membantu karena dapat memotong waktu pelatihan tanpa menurunkan akurasi. Secara performa komputasi, XGBoost terbukti jauh lebih efisien, melatih data $4,2\times$ lebih cepat dan memproses *flow* $4\times$ lebih cepat daripada *Random Forest*.

Hasil ini membuktikan bahwa kombinasi XGBoost dan seleksi fitur IG sangat cocok digunakan untuk mendeteksi DDoS di kampus yang memiliki keterbatasan sumber daya komputer. Di masa depan, kami berharap bisa menguji sistem ini menggunakan trafik kampus nyata secara langsung.

REFERENSI

- [1] NETSCOUT Systems, "NETSCOUT threat intelligence report," NETSCOUT Systems, Tech. Rep., 2023. [Online]. Available: <https://www.netscout.com/threatreport>
- [2] Cloudflare, "DDoS threat report Q3 2023," Cloudflare, Inc., Tech. Rep., 2023. [Online]. Available: <https://blog.cloudflare.com/ddos-threat-report-2023-q3>
- [3] G. B. A. Mthunzi, M. O. Adigun, and J. A. Ojo, "Adoption of BYOD in higher education: Security vulnerabilities and solutions," *Int. J. Comput. Theory Eng.*, vol. 12, no. 3, pp. 78–84, 2020.
- [4] M. N. Al-Mhiqani, R. Ahmad, and Z. Z. Abidin, "Cyber security challenges in higher education institutions: A systematic review," *Int. J. Adv. Comput. Sci. Appl.*, vol. 11, no. 7, pp. 125–135, 2020.

Tabel V
PERBANDINGAN VALIDASI DDoSHIELD DENGAN APLIKASI JARINGAN UMUM

Kriteria	DDoShield (Kami)	Wireshark	Snort
Metode Analisis	Machine Learning	Inspeksi Manual	Aturan Statis (<i>Signature</i>)
Validitas Hasil	Sangat Tinggi (Berdasarkan Dataset)	Standar Acuan Utama	Bergantung <i>Update</i> Aturan
Deteksi Serangan Baru	Bisa (Melihat Pola Anomali)	Bisa (Tergantung Analis)	Tidak Bisa
Kecepatan Deteksi	Sangat Cepat (0,0051 ms/flow)	Lambat (Manual)	Cepat (Otomatis)
Cara Analisis (Forensik)	Grafik Visual (<i>TreeSHAP</i>)	Baca Kode <i>Hex/Bytes</i>	Baca Teks Peringatan (<i>Alert</i>)

- [5] M. Ring, S. Wunderlich, D. Scheuring, D. Landes, and A. Hotho, "A survey of network-based intrusion detection data sets," *Comput. Secur.*, vol. 86, pp. 147–167, 2019.
- [6] S. M. Kasongo and Y. Sun, "Performance analysis of intrusion detection systems using a feature selection method on the UNSW-NB15 dataset," *J. Big Data*, vol. 7, no. 1, pp. 1–20, 2020.
- [7] I. Ullah and Q. H. Mahmoud, "A two-level flow-based anomalous activity detection system for IoT networks," *Electronics*, vol. 9, no. 3, p. 530, 2020.
- [8] O. H. Abdulganiyu, T. A. Tchakoucht, and Y. K. Saheed, "A systematic literature review for network intrusion detection system (IDS)," *Int. J. Inf. Secur.*, vol. 22, pp. 1125–1162, 2023.
- [9] V. Chandola, A. Banerjee, and V. Kumar, "Anomaly detection: A survey," *ACM Comput. Surv.*, vol. 41, no. 3, pp. 1–58, 2009.
- [10] A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, "Survey of intrusion detection systems: Techniques, datasets and challenges," *Cybersecurity*, vol. 2, no. 1, p. 20, 2019.
- [11] R. Vinayakumar, M. Alazab, K. P. Soman, P. Poornachandran, A. Al-Nemrat, and S. Venkatraman, "Deep learning approach for intelligent intrusion detection system," vol. 7, 2019, pp. 41 525–41 550.
- [12] R. Vinayakumar, K. P. Soman, and P. Poornachandran, "Applying convolutional neural network for network intrusion detection," pp. 1222–1228, 2017.
- [13] A. Thakkar and R. Lohiya, "A review of the advancement in intrusion detection datasets," *Procedia Comput. Sci.*, vol. 167, pp. 636–645, 2020.
- [14] T. Chen and C. Guestrin, "XGBoost: A scalable tree boosting system," pp. 785–794, 2016.
- [15] C. E. Shannon, "A mathematical theory of communication," *Bell Syst. Tech. J.*, vol. 27, no. 3, pp. 379–423, 1948.
- [16] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *J. Mach. Learn. Res.*, vol. 3, pp. 1157–1182, 2003.
- [17] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward generating a new intrusion detection dataset and intrusion traffic characterization," pp. 108–116, 2018.
- [18] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," vol. 30, 2017. [Online]. Available: <https://arxiv.org/abs/1705.07874>
- [19] G. Engelen, V. Rimmer, and W. Joosen, "Troubleshooting an intrusion detection dataset: the CICIDS2017 case study," pp. 7–12, 2021.